

Laboratorio 6

Task 3

Para evaluar cuál modelo es más adecuado para llevar a producción, se compararon ResNet50, InceptionV3 y MobileNetV2 utilizando cuatro métricas clave: accuracy, F1-score, tamaño del modelo y tiempo de inferencia.

Analizando la comparación de los resultados de los modelos podemos ver lo siguiente:

Modelo	Accuracy	F1_macro	Tamaño_MB	Inferencia_ms
ResNet50	0.9950	0.9950	90.04	9.92
InceptionV3	0.9817	0.9817	93.28	17.14
MobileNetV2	0.9933	0.9933	8.76	8.21

A partir de estos resultados, se observa que ResNet50 alcanza el mejor desempeño en términos de precisión, con un accuracy de 0.9950 y un F1-score prácticamente igual. MobileNetV2 le sigue muy de cerca con un accuracy de 0.9933, mientras que InceptionV3 queda por debajo con aproximadamente 0.9817. En términos únicamente de rendimiento predictivo, los tres modelos son buenos, pero la diferencia entre ResNet50 y MobileNetV2 es mínima, de apenas 0.17%, lo cual en la práctica no representa un cambio significativo en la calidad de las predicciones.

Sin embargo, al analizar las métricas relacionadas con eficiencia, las diferencias se vuelven mucho más importantes. ResNet50 e InceptionV3 tienen tamaños cercanos a los 90 MB, mientras que MobileNetV2 ocupa solamente alrededor de 8.7 MB. Esto significa que MobileNet es más de 10 veces menos pesado que los otros modelos. De la misma manera, el tiempo de inferencia también favorece a MobileNetV2, con aproximadamente 8.2 ms por imagen, contra 9.9 ms de ResNet50 y más de 17 ms de InceptionV3. Estas diferencias no son insignificantes, porque impactan directamente la experiencia del usuario y la viabilidad técnica del sistema en dispositivos con recursos limitados.

Esta relación entre tamaño y desempeño está directamente ligada a la arquitectura de cada modelo. ResNet e Inception están diseñados para maximizar la capacidad de representación a través de redes profundas y varias operaciones en paralelo, lo que incrementa significativamente la cantidad de parámetros. Por otro lado, MobileNetV2 utiliza convoluciones separables en profundidad, lo que reduce drásticamente la cantidad de cálculos y parámetros necesarios. Este diseño significa que hay que sacrificar un poco de expresividad matemática, pero a cambio se obtiene un modelo mucho más eficiente. Los resultados confirman que este sacrificio es mínimo en términos de accuracy, pero muy significativo en términos de recursos computacionales.

Considerando el contexto del proyecto, como los usuarios finales son agricultores guatemaltecos que utilizarán teléfonos Android de gama baja con aproximadamente 2GB de RAM y sin acceso a internet, la decisión tiene que priorizar la eficiencia y la capacidad de ejecución local. En este escenario, modelos como ResNet50 o InceptionV3, aunque son un poco más precisos, terminan siendo poco prácticos por su tamaño y consumo de recursos.

Podrían generar tiempos de carga altos, mayor uso de memoria e incluso problemas de ejecución en dispositivos limitados.

Por esto, la decisión recomendada es desplegar MobileNetV2 en producción. Este modelo ofrece un equilibrio óptimo entre precisión y eficiencia, manteniendo un desempeño casi igual al mejor modelo evaluado, pero con una reducción significativa en tamaño y tiempo de inferencia. Esto lo convierte en la opción más viable para un sistema de Edge AI completamente offline, garantizando que la aplicación sea rápida, funcional y accesible para los usuarios en condiciones reales de uso.